

BÁO CÁO PHẦN CỦA KIẾN

Đánh giá Mô hình & Kỹ thuật Hồi quy Nâng cao

CHƯƠNG 1: SO SÁNH ĐỘ ĐO SAI SỐ TRÊN TẬP TEST

1.1. Mục tiêu và Phương pháp

Mục tiêu của chương này là định lượng và so sánh hiệu suất dự báo của ba mô hình hồi quy đã được huấn luyện trong Phần 2 của đề án. Toàn bộ quá trình đánh giá được thực hiện trên tập kiểm tra (test set) chiếm 20% dữ liệu, được tách ra hoàn toàn trước bước huấn luyện nhằm đảm bảo tính khách quan.

Ba chỉ số đo lường được sử dụng theo yêu cầu của đề bài:

- MAE (Mean Absolute Error):** Sai số tuyệt đối trung bình, đơn vị triệu USD. Phản ánh trực quan mức độ lệch của dự báo so với giá trị thực.
- RMSE (Root Mean Squared Error):** Căn bậc hai trung bình bình phương sai số. Phạt nặng hơn với các sai số lớn, phù hợp để phát hiện dự báo cực kỳ lệch.
- R² (Hệ số xác định):** Tỷ lệ phần trăm biến động của Global_Sales được mô hình giải thích. Giá trị càng gần 1.0 thì mô hình càng tốt.

1.2. Kết quả so sánh

Nhóm tiến hành đánh giá đồng thời ba mô hình bắt buộc và một mô hình nâng cao trên cùng tập test. Kết quả được tổng hợp trong bảng sau:

Bảng 1: Tổng hợp độ đo sai số trên tập Test

Mô hình	MAE	RMSE	R ²	Xếp hạng
OLS Full Model	0.4821	0.8934	0.1134	#1
OLS Stepwise	0.4756	0.8812	0.1287	#2
Ridge Regression	0.4698	0.8701	0.1389	#3
Kernel Ridge*	0.4612	0.8645	0.1441	Tốt nhất ✓

(*) Kernel Ridge Regression được đánh giá trên tập con 100 mẫu test do chi phí tính toán $O(n^2)$.

1.3. Nhận xét và Phân tích

- Ridge Regression cho kết quả tốt nhất** trong nhóm mô hình tuyến tính ($R^2 = 0.1389$, $RMSE = 0.8701$). Kỹ thuật regularization L2 giúp kiểm soát phương sai

của ước lượng, đặc biệt hữu ích khi tập đặc trưng có 79 chiều sau one-hot encoding với nguy cơ đa cộng tuyến cao.

- **OLS Full Model có R^2 thấp nhất (0.1134)**, phản ánh hiện tượng overfitting do số biến lớn và multicollinearity giữa các cột Platform one-hot.
- **OLS Stepwise cải thiện nhẹ so với OLS Full ($R^2 = 0.1287$)** nhờ loại bỏ các biến không có ý nghĩa thống kê ($p\text{-value} > 0.05$). Tuy nhiên, vì bước backward elimination chỉ dựa trên p-value mà không kiểm soát multicollinearity, mức cải thiện còn hạn chế.
- **R^2 tổng thể thấp (0.11 – 0.14)** không phải lỗi mô hình mà phản ánh đặc trưng vốn có của dữ liệu doanh thu game: phần lớn sự biến động đến từ các yếu tố không quan sát được trong bộ dữ liệu như chiến lược marketing, thời điểm ra mắt và thương hiệu nhượng quyền.

CHƯƠNG 2: PHÂN TÍCH PHẦN DƯ (RESIDUAL ANALYSIS)

2.1. Mục tiêu và Mô hình được chọn

Theo yêu cầu đề bài mục 2.5, phân tích phần dư được thực hiện trên mô hình đạt kết quả tốt nhất trên tập test. Dựa trên bảng so sánh ở Chương 1, Ridge Regression được chọn làm mô hình để phân tích. Bốn biểu đồ chẩn đoán được vẽ nhằm kiểm tra các giả định cốt lõi của mô hình hồi quy tuyến tính theo chuẩn thống kê.

2.2. Biểu đồ 1 — Residuals vs Fitted

Hình 1: Residuals vs Fitted Values

Biểu đồ này vẽ phần dư (residuals = $y_{\text{thực}} - \hat{y}_{\text{dự đoán}}$) theo giá trị dự đoán của mô hình. Các điểm dữ liệu phân tán tương đối ngẫu nhiên và đối xứng quanh đường ngang $y = 0$, không biểu hiện xu hướng phi tuyến rõ ràng. Đường làm trơn LOWESS (đường cam) gần như nằm ngang ở vùng giá trị dự đoán thấp và trung bình, xác nhận mối quan hệ tuyến tính cơ bản giữa các đặc trưng và Global_Sales.

Tuy nhiên, ở vùng giá trị dự đoán lớn (fitted values > 3), phần dư có xu hướng dương và phân tán rộng hơn, gợi ý sự tồn tại của heteroscedasticity — phương sai phần dư tăng theo giá trị dự đoán. Đây là đặc trưng phổ biến trong dữ liệu doanh thu thực tế có phân phối lệch phải.

2.3. Biểu đồ 2 — Normal Q-Q Plot

Hình 2: Normal Q-Q Plot của Standardized Residuals

Biểu đồ Q-Q so sánh phân phối thực nghiệm của phần dư chuẩn hóa với phân phối chuẩn lý thuyết. Phần lớn các điểm nằm sát đường đỏ lý thuyết ở vùng trung tâm (-2 đến +2), xác nhận giả định phân phối chuẩn tương đối được thỏa mãn với khối dữ liệu chính.

Phần đuôi phải lệch mạnh khỏi đường chuẩn — đây là hệ quả trực tiếp từ đặc trưng phân phối lệch phải (right-skewed) của Global_Sales, nơi tồn tại các tựa game bom tấn có doanh thu cực cao như Wii Sports (82.53 triệu USD). Kết quả kiểm định Shapiro-Wilk ($p < 0.05$) cũng phù hợp với quan sát trực quan này. Để cải thiện, phép biến đổi $\log(\text{Global_Sales})$ được gợi ý như một hướng xử lý trong tương lai.

2.4. Biểu đồ 3 — Scale-Location

Hình 3: Scale-Location Plot

Biểu đồ Scale-Location vẽ căn bậc hai của giá trị tuyệt đối phần dư chuẩn hóa theo giá trị dự đoán, nhằm kiểm tra tính đồng đều của phương sai (homoscedasticity). Đường làm trơn LOWESS có xu hướng dốc lên rõ rệt, xác nhận hiện tượng heteroscedasticity: phương sai phần dư tăng khi giá trị dự đoán tăng.

Phát hiện này nhất quán với kết quả biểu đồ 1 và phản ánh cấu trúc thực tế của thị trường game — các tựa game có doanh thu cao thường có độ biến động lớn hơn nhiều so với các tựa game bình thường. Để khắc phục, có thể áp dụng Weighted Least Squares (WLS) hoặc biến đổi logarit biến mục tiêu trước khi huấn luyện.

2.5. Biểu đồ 4 — Leverage và Cook's Distance

Hình 4: Leverage vs Standardized Residuals (màu theo Cook's Distance)

Biểu đồ này kết hợp Leverage (mức độ "đặc biệt" của một điểm trong không gian đặc trưng) và **Cook's Distance** (tổng ảnh hưởng của điểm đó lên vector hệ số) để phát hiện các quan sát influential. Phân tích xác định được 315 điểm có Cook's Distance vượt ngưỡng $4/n$.

Các điểm outlier tập trung ở vùng Standardized Residuals lớn (> 5) với Leverage thấp, tức là chúng có phần dư lớn nhưng không gây ảnh hưởng mạnh đến ước lượng hệ số. Đây thường là các tựa game cực kỳ nổi tiếng (Nintendo blockbusters) có doanh thu thực tế vượt xa dự đoán của mô hình. Nhóm giữ nguyên các điểm này trong phân tích vì chúng là các quan sát hợp lệ, phản ánh thực tế thị trường chứ không phải lỗi dữ liệu.

CHƯƠNG 3: PHÂN TÍCH TẦM QUAN TRỌNG ĐẶC TRƯNG (FEATURE IMPORTANCE)

3.1. Phương pháp

Tầm quan trọng của từng biến được đánh giá qua độ lớn tuyệt đối của hệ số Ridge sau chuẩn hóa (standardized Ridge coefficients). Lý do sử dụng hệ số Ridge thay vì OLS là để tránh hiện tượng inflation của hệ số OLS khi có multicollinearity — với 79 đặc trưng sau one-hot encoding, các hệ số OLS có thể bị thổi phồng lên hàng tỷ đơn vị, mất hoàn toàn ý nghĩa diễn giải.

Bước chuẩn hóa (z-score standardization) được thực hiện bởi DataPipeline của thành viên KHIÊM trước khi huấn luyện, đảm bảo các hệ số có thể so sánh trực tiếp với nhau bất kể đơn vị đo lường gốc.

3.2. Kết quả và Nhận xét

Hình 5: Top 20 Feature Importance — Ridge Regression (hệ số đã chuẩn hóa)

- Publisher_Nintendo đứng đầu ($|\beta| = 1.574$):** Đây là kết quả hoàn toàn hợp lý về mặt kinh tế. Nintendo là nhà phát hành có doanh thu trung bình vượt trội nhờ các thương hiệu nhượng quyền kinh điển (Mario, Zelda, Pokémon). Mô hình đã học được rằng game mang nhãn Nintendo có xu hướng bán chạy hơn đáng kể.
- Platform_NES và Platform_GB ($|\beta| \approx 1.13$ – 1.32):** Các nền tảng cổ điển này có doanh thu trung bình cao trong dataset do chúng gắn liền với thời kỳ Nintendo thống trị thị trường (1985-1995). Tuy nhiên, cần lưu ý đây một phần phản ánh hiệu ứng của Publisher_Nintendo hơn là đặc trưng riêng của platform.
- User_Count xuất hiện trong top 10 ($|\beta| \approx 0.30$):** Số lượng người dùng đánh giá là proxy tốt cho mức độ phổ biến của game, có tương quan với doanh thu. Biến này nắm bắt thông tin về quy mô cộng đồng người chơi mà Critic_Score không thể hiện được.
- Genre_Platform ($|\beta| = 0.237$):** Thể loại Platform (game nhảy/chạy theo màn) có hệ số dương, phù hợp với thực tế rằng nhiều tựa game bom tấn của Nintendo (Mario series) thuộc thể loại này.

CHƯƠNG 4: KERNEL RIDGE REGRESSION — KỸ THUẬT NÂNG CAO (+0.5 điểm)

4.1. Động lực nghiên cứu

OLS và Ridge Regression giả định mối quan hệ tuyến tính toàn cục giữa đặc trưng và biến mục tiêu. Tuy nhiên, dữ liệu doanh thu game có thể chứa các phi tuyến tính cục bộ — ví dụ, mối quan hệ giữa Critic_Score và Global_Sales có thể tăng tốc đột ngột ở vùng điểm rất cao (90-99). Kernel Ridge Regression được triển khai để kiểm chứng giả thuyết này và bổ sung một mô hình phi tham số vào bộ so sánh.

4.2. Cơ sở lý thuyết

Kernel Ridge Regression là phương pháp mở rộng OLS sang không gian đặc trưng phi tuyến thông qua kernel trick, theo đúng công thức đề bài mục 2.4:

$$\hat{\mathbf{y}}(\mathbf{x}) = \mathbf{k}(\mathbf{x})^T (\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y}$$

Trong đó $\mathbf{K}$ là ma trận Gram với $K[i,j] = k(\mathbf{x}_i, \mathbf{x}_j)$, và $k(\cdot, \cdot)$ là hàm kernel RBF (Radial Basis Function):

$$k(\mathbf{x}, \mathbf{x}') = \exp(-\|\mathbf{x} - \mathbf{x}'\|^2 / 2\ell^2)$$

Tham số λ đóng vai trò regularization (tương tự Ridge), còn ℓ (length scale) kiểm soát độ rộng của vùng ảnh hưởng của mỗi điểm train. Cả hai tham số được chọn đồng thời qua 3-fold Cross-Validation.

4.3. Cài đặt

Thuật toán được cài đặt từ đầu bằng Python thuần và NumPy, không sử dụng thư viện sklearn hay scikit-learn, đảm bảo tính minh bạch và phù hợp yêu cầu đề bài. Các bước chính bao gồm: (1) tính ma trận Gram $\mathbf{K}$ bằng vectorized NumPy, (2) giải hệ tuyến tính $(\mathbf{K} + \lambda \mathbf{I})\alpha = \mathbf{y}$ bằng `numpy.linalg.solve` thay vì nghịch đảo trực tiếp để đảm bảo số trị ổn định, (3) dự đoán bằng tích $\mathbf{k}(\mathbf{x})^T \alpha$.

Do chi phí tính toán $O(n^2)$ khi tính ma trận Gram, Kernel Ridge Regression được huấn luyện trên tập con 300 mẫu train và đánh giá trên 100 mẫu test. Chỉ 4 biến số (Critic_Score, Critic_Count, User_Score, User_Count) được sử dụng để tránh "Curse of Dimensionality" — khi số chiều quá lớn, khoảng cách Euclidean mất khả năng phân biệt, khiến kernel weight gần như bằng nhau cho mọi cặp điểm.

4.4. Kết quả

Hình 6: Kernel Ridge vs OLS — ảnh hưởng của length scale ℓ (trái) và so sánh trực tiếp (phải)
Qua quá trình CV, cặp tham số tối ưu được chọn là $\lambda = 1.0$, $\ell = 1.0$. Kernel Ridge Regression đạt $\text{MAE} = 0.4612$, $\text{RMSE} = 0.8645$, $R^2 = 0.1441$ — cải thiện nhẹ so với Ridge tuyến tính trên tập con này.

Biểu đồ so sánh trực quan minh họa rõ sự khác biệt về cơ chế giữa hai phương pháp: đường dự đoán của Kernel uốn lượn theo cấu trúc cục bộ của dữ liệu, trong khi OLS chỉ có thể fit một đường thẳng toàn cục. Biểu đồ trái cho thấy ảnh hưởng của ℓ : ℓ nhỏ (0.3) gây overfit — đường dự đoán dao động mạnh theo từng điểm, trong khi ℓ lớn (5.0) gây underfit — đường dự đoán phẳng gần như một hằng số.

4.5. Hạn chế

- **Chi phí tính toán $O(n^2)$:** Không khả thi với toàn bộ 13,000+ mẫu train. Giải pháp mở rộng: Nyström approximation hoặc Random Fourier Features.
- **Không có hệ số diễn giải:** Kernel Ridge cho ra vector α thay vì β , không thể diễn giải trực tiếp tầm quan trọng đặc trưng.
- **Nhạy cảm với curse of dimensionality:** Phải giới hạn số features đầu vào, làm giảm thông tin so với Ridge tuyến tính dùng đủ 79 đặc trưng.

TÀI LIỆU THAM KHẢO

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning, 2nd ed. Springer. (Chương 3: Linear Regression; Chương 7: Nonlinear Models).

Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning, 2nd ed. Springer. (Chương 6: Kernel Smoothing Methods; Chương 12: Kernel Methods).

Wooldridge, J. M. (2015). Introductory Econometrics: A Modern Approach. Cengage Learning. (Chương 9: Phân tích phần dư và kiểm định giả định OLS).

Schölkopf, B., & Smola, A. J. (2002). Learning with Kernels. MIT Press. (Lý thuyết Kernel Ridge Regression và ma trận Gram).

Dữ liệu Video Games Sales (2016). Trích xuất từ Kaggle (kaggle.com/regorut/videogamesales) và sử dụng cho mục đích học thuật trong đồ án môn MTH00051.